

STA5021 Homework #1

2025712931 통계학과 신현수

50

1. 10

(10 points) Suppose that the two functions f, g are defined on a finite interval $[T_1, T_2]$, $T_1 < T_2$. Also assume that $\|f\|, \|g\| < \infty$. Show that the Cauchy-Schwarz inequality holds:

$$|\langle f, g \rangle| \leq \|f\| \|g\|.$$

Moreover, show that the equality holds if and only if $f = cg$ for some $c \in \mathbb{R}$.

(Sol)

다음과 같이 내적과 노름을 정의하자.

$$\langle f, g \rangle = \int_{T_1}^{T_2} f(t)g(t) dt, \quad \|f\| = \langle f, f \rangle^{1/2}.$$

임의의 $\lambda \in \mathbb{R}$ 에 대하여

$$0 \leq \|f - \lambda g\|^2 = \langle f - \lambda g, f - \lambda g \rangle = \|f\|^2 - 2\lambda \langle f, g \rangle + \lambda^2 \|g\|^2$$

가 성립한다.

먼저 $g \neq 0$ 인 경우를 보자. 이때

$$\lambda = \frac{\langle f, g \rangle}{\|g\|^2}$$

로 두면

$$0 \leq \|f\|^2 - \frac{\langle f, g \rangle^2}{\|g\|^2}$$

이므로

$$\langle f, g \rangle^2 \leq \|f\|^2 \|g\|^2$$

를 얻는다. 양변에 제곱근을 취하면

$$|\langle f, g \rangle| \leq \|f\| \|g\|$$

가 된다.

한편 $g = 0$ 이면 $\langle f, g \rangle = 0$ 이므로 위 부등식은 자명하게 성립한다. 따라서 모든 f 와 g 에 대하여

$$|\langle f, g \rangle| \leq \|f\| \|g\|$$

가 성립한다.

이제 equality 조건을 보자. 조금 더 정확하게 말하면, equality가 성립할 필요충분조건은 f 와 g 가 선형종속이라는 것이다. L^2 의 의미에서는 거의 모든 점에서 선형종속이라는 뜻이다.

특히 $g \neq 0$ 이면, equality가 성립할 필요충분조건은 어떤 $c \in \mathbb{R}$ 가 존재하여 $f = cg$ a.e.가 되는 것이다.

이를 보이기 위해 먼저 $g \neq 0$ 라고 하자. 코시-슈바르츠 부등식에서 equality가 성립한다는 것은

$$|\langle f, g \rangle| = \|f\| \|g\|$$

라는 뜻이고, 이는

$$\langle f, g \rangle^2 = \|f\|^2 \|g\|^2$$

와 동치이다. 이 식을 앞에서 얻은 표현에 대입하면

$$\left\| f - \frac{\langle f, g \rangle}{\|g\|^2} g \right\|^2 = 0$$

이 된다. 따라서 어떤 $c \in \mathbb{R}$ 에 대하여

$$f = \frac{\langle f, g \rangle}{\|g\|^2} g = cg$$

a.e.가 성립한다.

반대로 $f = cg$ 라고 하자. 그러면

$$\langle f, g \rangle = \langle cg, g \rangle = c\|g\|^2$$

이고

$$\|f\| = \|cg\| = |c| \|g\|$$

이므로

$$|\langle f, g \rangle| = |c| \|g\|^2 = \|f\| \|g\|$$

가 된다. 따라서 equality가 성립한다.

마지막으로 $g = 0$ 인 경우에도 equality는 자명하게 성립하며, 이 경우 역시 f 와 g 가 선형종속이라는 진술에 포함된다.

2.10

(10 points) Let $X \in \mathbb{R}^{p \times q}$ and define

$$u = \text{trace}(XAX^\top B),$$

where A and B are symmetric matrices. Show that

$$\frac{\partial u}{\partial X} = 2BXA.$$

(Sol)

$X \in \mathbb{R}^{p \times q}$, $A \in \mathbb{R}^{q \times q}$, $B \in \mathbb{R}^{p \times p}$ 이고 $A = A^\top$, $B = B^\top$ 라고 하자. 다음을 정의하자.

$$u = \text{tr}(XAX^\top B).$$

이제 u 의 differential을 계산하자.

곱의 미분법칙을 이용하면

$$du = \text{tr}(dX A X^\top B) + \text{tr}(X A dX^\top B)$$

가 된다. 첫 번째 항에 대하여 trace의 순환 성질을 쓰면

$$\text{tr}(dX A X^\top B) = \text{tr}(A X^\top B dX)$$

이다. 또 A 와 B 가 symmetric이므로

$$(BXA)^\top = A^\top X^\top B^\top = A X^\top B$$

이어서, 첫 번째 항은

$$\text{tr}((BXA)^\top dX)$$

로 쓸 수 있다.

두 번째 항에 대해서는

$$\text{tr}(X A dX^\top B) = \text{tr}(BXA dX^\top)$$

이고, 여기서 $\text{tr}(M dX^\top) = \text{tr}(M^\top dX)$ 를 이용하면

$$\text{tr}(BXA dX^\top) = \text{tr}((BXA)^\top dX)$$

를 얻는다. 따라서

$$du = 2 \text{tr}((BXA)^\top dX)$$

이다.

행렬 gradient의 정의에 의해

$$du = \text{tr} \left(\left(\frac{\partial u}{\partial X} \right)^\top dX \right)$$

이므로, 두 식을 비교하면

$$\frac{\partial u}{\partial X} = 2BXA$$

를 얻는다.

3.

(10 points) In slide 3, we expressed

$$x_n(t) = \sum_{k=1}^K c_{nk} \phi_k(t)$$

for some $c_{nk} \in \mathbb{R}$ ($n = 1, \dots, N$; $k = 1, \dots, K$). One can show that

$$\bar{x}(t) = \sum_{k=1}^K a_k \phi_k(t)$$

and

$$\text{cov}_X(s, t) = \sum_{m=1}^K \sum_{k=1}^K b_{mk} \phi_m(s) \phi_k(t).$$

Find expressions for a_k and b_{mk} .

(Sol)

다음과 같이

$$x_n(t) = \sum_{k=1}^K c_{nk} \phi_k(t), \quad n = 1, \dots, N$$

라고 하자.

표본평균함수는

$$\bar{x}(t) = \frac{1}{N} \sum_{n=1}^N x_n(t)$$

이므로, $x_n(t)$ 의 전개식을 대입하면

$$\bar{x}(t) = \frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K c_{nk} \phi_k(t) = \sum_{k=1}^K \left(\frac{1}{N} \sum_{n=1}^N c_{nk} \right) \phi_k(t)$$

가 된다. 문제에서

$$\bar{x}(t) = \sum_{k=1}^K a_k \phi_k(t)$$

라고 썼으므로

$$a_k = \frac{1}{N} \sum_{n=1}^N c_{nk}$$

를 얻는다.

이제 표본 공분산함수를

$$\text{cov}_X(s, t) = \frac{1}{N} \sum_{n=1}^N (x_n(s) - \bar{x}(s))(x_n(t) - \bar{x}(t))$$

라고 하자. 그러면

$$x_n(s) - \bar{x}(s) = \sum_{m=1}^K (c_{nm} - a_m) \phi_m(s)$$

이고

$$x_n(t) - \bar{x}(t) = \sum_{k=1}^K (c_{nk} - a_k) \phi_k(t)$$

이다. 따라서

$$\begin{aligned} \text{cov}_X(s, t) &= \frac{1}{N} \sum_{n=1}^N \left[\sum_{m=1}^K (c_{nm} - a_m) \phi_m(s) \right] \left[\sum_{k=1}^K (c_{nk} - a_k) \phi_k(t) \right] \\ &= \sum_{m=1}^K \sum_{k=1}^K \left[\frac{1}{N} \sum_{n=1}^N (c_{nm} - a_m)(c_{nk} - a_k) \right] \phi_m(s) \phi_k(t). \end{aligned}$$

문제에서

$$\text{cov}_X(s, t) = \sum_{m=1}^K \sum_{k=1}^K b_{mk} \phi_m(s) \phi_k(t)$$

라고 하였으므로

$$b_{mk} = \frac{1}{N} \sum_{n=1}^N (c_{nm} - a_m)(c_{nk} - a_k)$$

를 얻는다.

즉, a_k 는 k 번째 coefficient의 표본평균이고, b_{mk} 는 coefficient vector들의 표본 공분산행렬의 (m, k) 원소이다.

만약 수업 노트에서 표본 공분산을 $1/N$ 대신 $1/(N-1)$ 로 정의했다면, 같은 유도를 통해

$$b_{mk} = \frac{1}{N-1} \sum_{n=1}^N (c_{nm} - a_m)(c_{nk} - a_k)$$

를 얻게 된다.

(20 points) Summarize the group activity conducted in the March 9 class. The summary should be **one page in length** and must be written individually (i.e., not with your group members). You may write the summary in Korean or English, and you may use any standard format you are familiar with (but avoid using excessively small or large {font sizes, page margins, line margins, etc}). The summary should include the following:

- A summary of your group's presentation from the March 9 class.
 - If you wish, you may further develop the rule proposed by your group, or modify the rule that was presented in class.
 - You can include simulated datasets and computer codes to facilitate your summary.
- A comparison between your group's outlier detection rule and that of at least one other group.
 - If you do not remember the work of the other groups, read "Functional Boxplots" (Sun and Genton, 2011) and compare your rule with the one proposed in the paper.

우리 조에서는 전체적인 수준(level) 차이보다는 shape 차이가 주된 특징인 outlying curve를 탐지하기 위해 FPCA를 사용하는 방법을 논의했다. 핵심은 functional data에서 이상치가 반드시 모든 구간에서 평균으로부터 멀리 떨어진 곡선일 필요는 없다는 점이다. 어떤 곡선은 대부분의 구간에서는 중심에 가깝게 머물지만, 국소적인 bump가 있거나 진동 패턴이 다르거나 곡률이 다르기 때문에 비정상적으로 보일 수 있다. 그래서 원래의 함수공간에서 거리만 보는 대신, functional principal component를 통해 데이터를 살펴보는 것이 우리 논의의 출발점이었다.

곡선을 smoothing하고 중심화한 뒤에는 각 관측치를 대략

$$X_i(t) - \mu(t) \approx \sum_{k=1}^K \xi_{ik} \phi_k(t)$$

와 같이 나타낼 수 있다. 여기서 ϕ_k 는 고유함수이고, ξ_{ik} 는 FPC score이다. 우리 조의 아이디어는 이 score vector가 각 곡선이 평균함수로부터 어떻게 다른지를 저차원으로 요약해 준다는 점에 있었다. 많은 예시에서 첫 번째 주성분은 전체적인 magnitude를 주로 반영하고, 두 번째나 세 번째 주성분은 보다 구조적인 shape 차이를 포착하는 경우가 많다. 따라서 수준 면에서는 정상적으로 보이는 곡선이라도 shape 이 다르면 score 공간에서는 눈에 띄게 벗어날 수 있다. 이런 점에서 FPCA는 shape outlier를 탐지하는 자연스러운 도구라고 생각했다.

우리 조의 규칙을 조금 확장해서 생각해 보면, 각 score를 따로 보는 것보다는 joint score vector를 이용하는 편이 더 좋다고 생각한다. 즉, 앞의 몇 개 주성분을 유지한 뒤 score 공간에서 주된 군집으로부터 멀리 떨어진 관측치를 찾는 방식이다. 이 공간에서 robust distance를 사용하는 방법이 각 성분마다 단순 cutoff를 두는 방법보다 더 적절할 가능성이 높다. 그 이유는 이상한 곡선이 꼭 한 방향으로만 극단적인 것이 아니라, 여러 score의 특정한 조합에서 비정상적으로 나타나는 경우가 많기 때문이다. 이런 설명은 shape outlier가 종종 하나의 방향에서만 튀는 것이 아니라 여러 방향의 결합으로 드러난다는 점과도 잘 맞는다.

다른 조에서는 거리 기반(distance-based) 방법을 발표했다. 내가 이해한 바로는 중심 곡선으로부터의 거리나 곡선들 사이의 pairwise distance를 이용해 어떤 관측치가 다른 곡선들로부터 멀리 떨어져 있는지를 보고 outlier를 판단하는 방식이었다. 이 접근은 단순하고 설명하기 쉽다는 분명한 장점이 있다. 계산이 비교적 쉽고, 직관적이고 하고, magnitude outlier에는 대체로 잘 작동한다. 예를 들어 하나의 곡선이 전체적으로 다른 곡선들보다 지속적으로 위나 아래에 있으면, 거리 기반 방법은 이를 빠르게 탐지할 수 있다. 하지만 shape outlier의 경우에는 항상 전체 거리값이 크게 나타나는 것은 아니다. 어떤 곡선이 짧은 부분구간에서만 다른 형태를 보인다면, 전체 적분거리 기준으로는 차이가 희석되어 놓칠 수 있다.

이와 비교하면 FPCA 기반 아이디어는 shape 차이를 탐지하는 데 더 적합해 보인다. 데이터를 주요 변동 방향으로 사영하면 서로 다른 유형의 variation을 보다 명확하게 분리할 수 있고, 왜 어떤 곡선이 이상한지에 대한 해석도 더 쉬워진다. 물론 두 방법이 반드시 경쟁적인 관계라고 생각하지는 않는다. 실제로는 거리 기반 규칙으로 1차 선별을 한 뒤, FPCA를 사용해 표시된 곡선이 magnitude 때문인지 shape 때문인지 구분하는 방식이 더 실용적일 수 있다. 전체적으로 이번 조별 활동은 functional data에서 magnitude outlier와 shape outlier의 차이를 더 신중하게 생각해 보게 해 주었고, 왜 그 구분이 실제 분석에서 중요한지도 보여 주었다.